

Series de tiempo


Modelos de Mercadotecnia

Jorge de la Vega Góngora

Maestría de Mercadotecnia

Sesión 2





Datos Temporales

1 **Análisis de series de tiempo**

- **Introducción a las series de tiempo**
- Enfoque descriptivo (Descomposición de series temporales)
- Suavizamiento
- Suavizamiento Avanzado

2 **Modelos ARIMA**

- Metodología de Box-Jenkins
- Análisis Box-Jenkins
- Ruido blanco
- Modelos AR, MA y ARMA

3 **Anexo**

Introducción

- Las *series de tiempo* son muy comunes en la vida cotidiana diaria contemporánea. Existe una gran cantidad de aplicaciones para las series de tiempo.

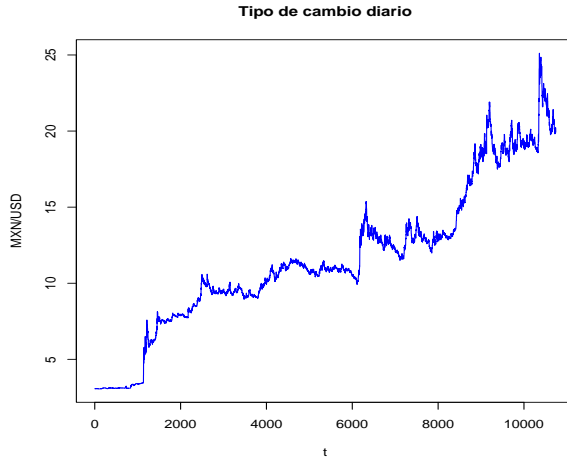
Series de tiempo

- Una **serie de tiempo** $\{y_t\}$ es una sucesión cronológica de observaciones, indexadas por un conjunto de índices \mathcal{T} que usualmente representa tiempo, de un fenómeno que se mide a través una variable y_t .
- Usualmente se consideran tiempos *igualmente espaciados*, pero no es necesario. Las series que tienen observaciones que no están regularmente espaciadas se llaman *series irregulares*.
- Cualquier sucesión de observaciones puede transformarse en una serie regular simplemente adoptando una escala de tiempo suficientemente fina o suficientemente gruesa. Entre observaciones adyacentes separadas por más de una unidad en esta escala, se registran valores no disponibles (**NA** o **ND**).
- En series irregulares, se debe asegurar que se está midiendo la misma cantidad. Por ejemplo, en ventas semanales, puede que no se registre en una semana. Esto puede producir, o un dato no disponible, o un valor que se adiciona a las ventas de la siguiente semana.


- La propiedad de *orden* es la que es crucial a los datos que conforman a la serie de tiempo. A diferencia de una muestra aleatoria de una v.a. X_n , las observaciones de una serie de tiempo están *ordenadas* por el índice temporal.
- La serie de tiempo que toma T valores se puede representar como la sucesión y_1, y_2, \dots, y_T , o bien, con la siguiente expresión: $\{y_t\}_{t=1}^T$.
- Usualmente, una serie de tiempo se visualiza mediante una gráfica $\{(t, y_t)\}$ y uniendo los puntos que son consecutivos en el tiempo.

Veamos algunos ejemplos.


Ejemplos: tipos de cambio



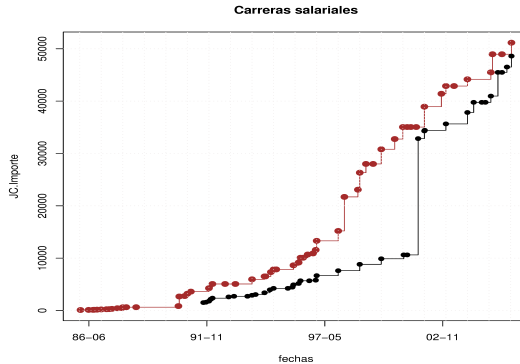
Ejemplos: Diferencias en los tipos de cambio



Ejemplos: Ruido Blanco

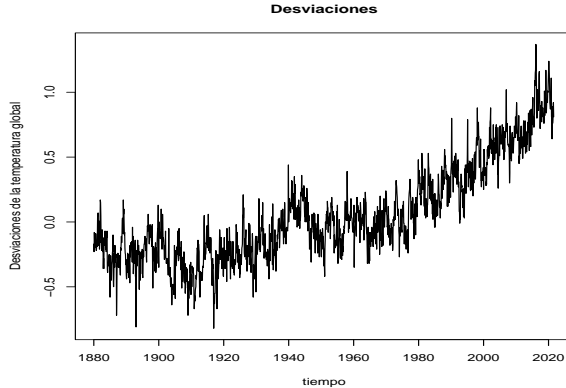


Ejemplos




Ejemplos

```
data <- read.csv("https://data.giss.nasa.gov/gistemp/taledata_v4/GLB.Ts+dSST.csv",skip=1)
data <- data[,2:13]; A <- t(data)
dim(A) <- c(1704,1)
A <- ts(as.numeric(A),start = 1880,freq=12)
plot(A,main = "Desviaciones", xlab = "tiempo", ylab = "Desviaciones de la temperatura global")
```



Ejemplos



Otros ejemplos de series temporales

- Otras situaciones prácticas que dan origen a las series de tiempo:
 - Ventas mensuales de vehículos de una agencia.
 - Número de desempleados en el tiempo (Índices de empleo).
 - Demanda mensual o trimestral de cualquier producto.
 - Demanda intermitente de productos, como partes de avión.
 - Población de una ciudad o un país a lo largo del tiempo.
 - Proporción de células cancerígenas en un órgano cada semana.
 - Índices de las diferentes bolsas de valores, o bien, los precios de productos financieros.
- Las fuentes de las series de tiempo pueden ser muy variadas, muchas son de origen industrial (en los procesos de producción), o bien, de naturaleza económica, física, financiera, médica, mercadotécnica, etc.

Una serie de tiempo se puede analizar con varios propósitos en mente. Nos interesa comprender el comportamiento de la variable y_t a lo largo del tiempo,

- para comprender sus fluctuaciones con respecto a un valor promedio, (variabilidad de la serie);
- identificar tendencia y nivel de la serie,
- para proyectar su posible comportamiento hacia el futuro, generando pronósticos y predicciones útiles para la planeación y toma de decisiones;
- para tratar de encontrar un modelo matemático que explique el *proceso generador de los datos* así como su *comportamiento*, a través de si misma o de otros posibles *predictores*.

Un supuesto fundamental de las series de tiempo es que es factible que *el comportamiento pasado de una variable nos ayude a explicar el actual o futuro*.

Series de tiempo vs. pronósticos

- Pronosticar y analizar una serie de tiempo son dos actividades distintas.
 - Un *pronóstico* es una visión de un futuro incierto.
 - *Analizar una serie de tiempo* es describir el proceso generador de los datos.
- Podemos analizar una serie de tiempo sin considerar como objetivo hacer pronósticos, así como podemos hacer pronósticos sin pensar en series de tiempo (o de hecho cualquier otro tipo de análisis).
- Los principales precursores de la actividad de pronóstico son la construcción de un modelo adecuado basado en el desarrollo histórico de la serie y la utilización de información relevante al posible desarrollo futuro de la serie.

Hay dos enfoques para trabajar con las series de tiempo:

1. El **enfoque descriptivo**, que describe y resume en forma concisa un conjunto de datos, mediante estadísticas sumarias y/o gráficas que puedan ayudar a tener una visión general del comportamiento de la serie, pero que no necesariamente ayuda a comprender la naturaleza de ese comportamiento. Esto incluye el *suavizamiento* de la serie, y los *métodos de descomposición*.
2. El **enfoque inferencial**, cuyo objetivo fundamental es utilizar datos de una muestra para realizar inferencias, que sean válidas para toda la población de donde se obtuvo la muestra. Incluye los *modelos de predicción*. En las series de tiempo, la población sobre la que se desea inferir depende del tipo de análisis y/o modelo que se emplee ya sea *procesos estocásticos* o bien *modelos estructurales*.

1 **Análisis de series de tiempo**

- Introducción a las series de tiempo
- **Enfoque descriptivo (Descomposición de series temporales)**
- Suavizamiento
- Suavizamiento Avanzado

2 **Modelos ARIMA**

- Metodología de Box-Jenkins
- Análisis Box-Jenkins
- Ruido blanco
- Modelos AR, MA y ARMA

3 **Anexo**

Componentes de una serie de tiempo

Una forma de modelar una serie de tiempo se obtiene al suponer que está conformada de diferentes componentes. Los componentes básicos son los siguientes:

- *Tendencia*: el movimiento hacia arriba o hacia abajo que caracteriza a una serie de tiempo en un periodo de tiempo dado. Muestra el crecimiento o decline de una serie en el largo plazo.
- *Ciclo*: se refiere a movimientos recurrentes hacia arriba o hacia abajo alrededor del nivel de tendencia. Usualmente son movimientos que se observan en periodos mayores a un año. En muchas ocasiones no se separa explícitamente y se considera parte de la tendencia.
- *Estacionalidad*: es el comportamiento que muestra una serie a lo largo de un periodo de tiempo, típicamente un año, y que se repite durante varios periodos.
- *Error*: se refiere a la parte de la serie que es completamente aleatoria; es el error estadístico que se presenta por incertidumbre.

Método clásico de descomposición. I

El método de descomposición clásico para series de tiempo tiene el objetivo de separar los componentes de una serie de tiempo. Este método supone que una serie de tiempo se puede escribir como una función de tres componentes:

$$X_t = f(TC_t, S_t, E_t), \quad \text{donde:}$$

- f es una función que relaciona los componentes,
- TC es un componente de tendencia-ciclo,
- S es un componente estacional,
- E es el componente de error o ruido de la serie.

Método clásico de descomposición. II

El método de descomposición se debe a varias personas, principalmente a Macauley (1930). Aquí se supondrá que el modelo es *multiplicativo*, los componentes se multiplican (la función f es el producto):

$$X_t = S_t \times TC_t \times E_t$$

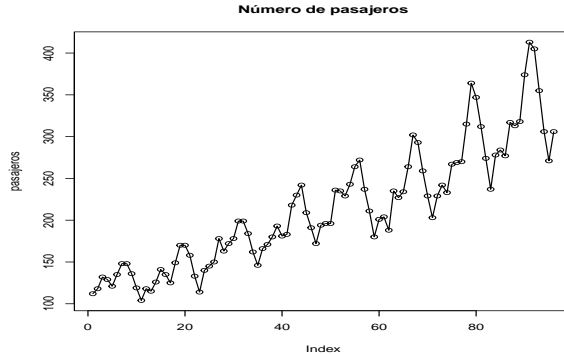
Mostraré el método a través de un ejemplo. Se tienen 8 años de datos mensuales del número de pasajeros internacionales de una línea aérea. La serie se muestra en la figura siguiente.

```
pasajeros <- c(112, 118, 132, 129, 121, 135, 148, 148, 136, 119, 104, 118,  
115, 126, 141, 135, 125, 149, 170, 170, 158, 133, 114, 140,  
145, 150, 178, 163, 172, 178, 199, 199, 184, 162, 146, 166,  
171, 180, 193, 181, 183, 218, 230, 242, 209, 191, 172, 194,  
196, 196, 236, 235, 229, 243, 264, 272, 237, 211, 180, 201,  
204, 188, 235, 227, 234, 264, 302, 293, 259, 229, 203, 229,  
242, 233, 267, 269, 270, 315, 364, 347, 312, 274, 237, 278,  
284, 277, 317, 313, 318, 374, 413, 405, 355, 306, 271, 306)  
n <- length(pasajeros) #número de observaciones disponibles  
n
```

[1] 96

Método clásico de descomposición. III

```
plot(pasajeros, type="o", main="Número de pasajeros")
```



Para dar formato de serie de tiempo, usamos la función `ts`:


Método clásico de descomposición. IV

```
ts.pasajeros <- ts(data = pasajeros, start = c(1949,1), frequency = 12)
ts.pasajeros
```

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
1949	112	118	132	129	121	135	148	148	136	119	104	118
1950	115	126	141	135	125	149	170	170	158	133	114	140
1951	145	150	178	163	172	178	199	199	184	162	146	166
1952	171	180	193	181	183	218	230	242	209	191	172	194
1953	196	196	236	235	229	243	264	272	237	211	180	201
1954	204	188	235	227	234	264	302	293	259	229	203	229
1955	242	233	267	269	270	315	364	347	312	274	237	278
1956	284	277	317	313	318	374	413	405	355	306	271	306

```
plot(ts.pasajeros, main = "Número de pasajeros 1949:1957", type="o", pch=16, col="red", lwd=2)
```

Método clásico de descomposición. V



Pasos del método de descomposición I

- Aplicaremos los siguientes pasos a los datos:

Paso 1 Se calcula un promedio móvil de tamaño 12 y se coloca en el mes de julio (se centra con respecto a la unidad de tiempo, que aquí es años). La observación de julio de 1949 por ejemplo, se calcula como:

$$\frac{112 + 118 + 132 + \cdots + 119 + 104 + 118}{12} = 126.667$$

La siguiente observación para agosto es $126.67 - 112/12 + 115/12 = 126.917$ y así sucesivamente. Habrá seis valores perdidos al principio y cinco al final, por los promedios considerados. Esto genera los siguientes datos:

Pasos del método de descomposición II


```
paso1 <- rep(NA,n)
for(i in 1:(n-6))
paso1[i+6] <- mean(ts.pasajeros[i:(i+11)])
```

```
paso1
[1] NA NA NA NA NA NA 126.6667 126.9167
[9] 127.5833 128.3333 128.8333 129.1667 130.3333 132.1667 134.0000 135.8333
[17] 137.0000 137.8333 139.6667 142.1667 144.1667 147.2500 149.5833 153.5000
[25] 155.9167 158.3333 160.7500 162.9167 165.3333 168.0000 170.1667 172.3333
[33] 174.8333 176.0833 177.5833 178.5000 181.8333 184.4167 188.0000 190.0833
[41] 192.5000 194.6667 197.0000 199.0833 200.4167 204.0000 208.5000 212.3333
[49] 214.4167 217.2500 219.7500 222.0833 223.7500 224.4167 225.0000 225.6667
[57] 225.0000 224.9167 224.2500 224.6667 226.4167 229.5833 231.3333 233.1667
[65] 234.6667 236.5833 238.9167 242.0833 245.8333 248.5000 252.0000 255.0000
[73] 259.2500 264.4167 268.9167 273.3333 277.0833 279.9167 284.0000 287.5000
[81] 291.1667 295.3333 299.0000 303.0000 307.9167 312.0000 316.8333 320.4167
[89] 323.0833 325.9167 328.2500 NA NA NA NA NA
```

Si se tuvieran datos trimestrales, el promedio móvil sería de tamaño 4 y se colocaría en el tercer trimestre. Si los datos fueran semestrales, el promedio móvil sería de tamaño dos y se colocaría en el segundo semestre. Una gráfica del paso 1 muestra una serie básicamente suave, correspondiente a la tendencia. El paso 2 ayuda a centrar los datos en el lugar correcto

```
plot(paso1)
```

Pasos del método de descomposición III



Pasos del método de descomposición IV

Paso 2 Se calcula un promedio móvil de tamaño 2 del promedio móvil del paso anterior y se coloca el primer promedio móvil en el mes de julio de 1949. Esto da un *promedio móvil centrado* de tamaño 12 al final. La primera observación en julio de 1949 es $(126.667 + 126.917)/2 = 126.792$. Al final se pierde un dato más. Este paso genera se genera de la siguiente manera:

```
paso2 <- rep(NA,n)
for(i in 1:(n-6)) paso2[6+i] <- mean(paso1[(6+i):(7+i)])
paso2
```


[1]	NA	NA	NA	NA	NA	NA	126.7917	127.2500
[9]	127.9583	128.5833	129.0000	129.7500	131.2500	133.0833	134.9167	136.4167
[17]	137.4167	138.7500	140.9167	143.1667	145.7083	148.4167	151.5417	154.7083
[25]	157.1250	159.5417	161.8333	164.1250	166.6667	169.0833	171.2500	173.5833
[33]	175.4583	176.8333	178.0417	180.1667	183.1250	186.2083	189.0417	191.2917
[41]	193.5833	195.8333	198.0417	199.7500	202.2083	206.2500	210.4167	213.3750
[49]	215.8333	218.5000	220.9167	222.9167	224.0833	224.7083	225.3333	225.3333
[57]	224.9583	224.5833	224.4583	225.5417	228.0000	230.4583	232.2500	233.9167
[65]	235.6250	237.7500	240.5000	243.9583	247.1667	250.2500	253.5000	257.1250
[73]	261.8333	266.6667	271.1250	275.2083	278.5000	281.9583	285.7500	289.3333
[81]	293.2500	297.1667	301.0000	305.4583	309.9583	314.4167	318.6250	321.7500
[89]	324.5000	327.0833	NA	NA	NA	NA	NA	NA

Si los datos fueran trimestrales o semestrales, siempre el segundo promedio móvil es de tamaño 2 y se coloca a la misma altura del primer promedio móvil.

Una gráfica del paso 2 es como la siguiente, que muestra la parte de tendencia de la serie

```
plot(paso2)
points(paso1,col="red") # solo se añade para comparar
```

Pasos del método de descomposición V



Pasos del método de descomposición VI

Paso 3 Se divide la columna generada en el paso anterior entre los datos y se multiplican por 100 para que puedan ser expresados como porcentajes. Este procedimiento separa el componente de tendencia-ciclo de los datos, pues los promedios móviles dobles eliminan el error y la estacionalidad y precisamente capturan la tendencia de los datos:

$$R_t = \frac{X_t}{TC_t} = S_t \times E_t$$

```
Rt <- 100*ts.pasajeros/paso2
```

Paso 4 Para separar el componente estacional S_t de la serie, hay que calcular los promedios de los valores R_t en cada mes.

```
St <- numeric(12)
for(i in 0:11)
St[ifelse((7+i) %% 12 == 0, 12, (7+i) %% 12)] <- mean(Rt[(1:n) %% 12 == i], na.rm = T)/100

St

[1] 1.0988912 1.1997467 1.1879806 1.0564024 0.9200596 0.7980033 0.9052642
[8] 0.9108800 0.9030236 1.0322468 0.9862632 0.9787807
```

Así, el factor estacional para el los meses de enero es 0.9106, para los meses de febrero es 0.8346 y así sucesivamente (recuerden que originalmente se multiplicaron los datos por 100, por eso se dividen por 100 ahora).

Pasos del método de descomposición VII

Paso 5 Por último, el componente de error se obtiene dividiendo la serie sin tendencia R_t por los factores estacionales:

$$E_t = R_t / S_t = \frac{S_t \times E_t}{S_t}$$

```
Et <- Rt/(100*St)
```

```
Et
```

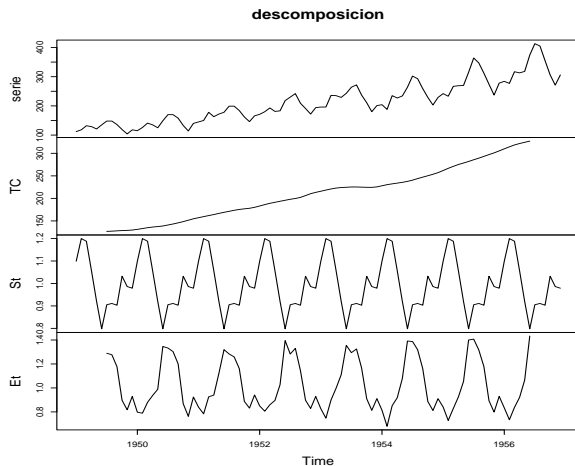
	Jan	Feb	Mar	Apr	May	Jun	Jul
1949	NA	NA	NA	NA	NA	NA	1.2894237
1950	0.7973405	0.7891459	0.8797194	0.9367786	0.9886775	1.3457010	1.3326350
1951	0.8397848	0.7836598	0.9258544	0.9401205	1.1216665	1.3192117	1.2836515
1952	0.8497551	0.8057194	0.8593903	0.8956806	1.0274653	1.3949710	1.2829092
1953	0.8263858	0.7476788	0.8992370	0.9979205	1.1107337	1.3551345	1.2942052
1954	0.8142179	0.6799482	0.8517317	0.9186188	1.0793904	1.3914855	1.3871279
1955	0.8410770	0.7282787	0.8289577	0.9252548	1.0537137	1.3999770	1.4071481
1956	0.8337970	0.7343188	0.8374716	0.9208660	1.0651149	1.4328756	NA
	Aug	Sep	Oct	Nov	Dec		
1949	1.2768584	1.1769858	0.8965587	0.8174304	0.9291573		
1950	1.3036044	1.2008081	0.8681313	0.7627460	0.9245469		
1951	1.2585888	1.1613008	0.8874979	0.8314543	0.9413438		
1952	1.3300483	1.1445852	0.8971310	0.8288109	0.9289082		
1953	1.3252026	1.1666677	0.9101676	0.8130999	0.9105082		
1954	1.3185323	1.1604082	0.8864981	0.8119424	0.9099254		
1955	1.3166484	1.1781958	0.8932374	0.7983420	0.9298383		
1956	NA	NA	NA	NA	NA		

Una gráfica con cada uno de los componentes de la serie se muestra en la figura siguiente.

Pasos del método de descomposición VIII

```
descomposicion <- data.frame(serie = ts.pasajeros, TC = paso2, St = St, Et = Et)  
plot.ts(descomposicion)
```


Pasos del método de descomposición IX



La función `decompose` en R permite realizar todos los pasos de manera eficiente y rápida.

Pasos del método de descomposición X

```
plot(decompose(ts.pasajeros))
```



Pasos del método de descomposición XI

Con cada uno de los componentes se puede reproducir el dato original. Por ejemplo, para el dato de Enero de 1950, que es 115, los componentes son: $TC = 131.25$, $S = 1.0988912$ y $E = 0.7973405$. Entonces

$$115 = 131.25 \times 1.0988912 \times 0.7973405$$

Los componentes finalmente se ven como en la tabla que se muestra a continuación:

Pasos del método de descomposición XII

```
descomposicion$St <- St  
descomposicion$Et <- Et  
head(descomposicion,25)
```

	serie	TC	St	Et
1	112	NA	1.0988912	NA
2	118	NA	1.1997467	NA
3	132	NA	1.1879806	NA
4	129	NA	1.0564024	NA
5	121	NA	0.9200596	NA
6	135	NA	0.7980033	NA
7	148	126.7917	0.9052642	1.2894237
8	148	127.2500	0.9108800	1.2768584
9	136	127.9583	0.9030236	1.1769858
10	119	128.5833	1.0322468	0.8965587
11	104	129.0000	0.9862632	0.8174304
12	118	129.7500	0.9787807	0.9291573
13	115	131.2500	1.0988912	0.7973405
14	126	133.0833	1.1997467	0.7891459
15	141	134.9167	1.1879806	0.8797194
16	135	136.4167	1.0564024	0.9367786
17	125	137.4167	0.9200596	0.9886775
18	149	138.7500	0.7980033	1.3457010
19	170	140.9167	0.9052642	1.3326350
20	170	143.1667	0.9108800	1.3036044
21	158	145.7083	0.9030236	1.2008081
22	133	148.4167	1.0322468	0.8681313
23	114	151.5417	0.9862632	0.7627460
24	140	154.7083	0.9787807	0.9245469
25	145	157.1250	1.0988912	0.8397848

- La ventaja de tener identificados los componentes de la serie es que ahora podemos pronosticar cada componente por separado.
- En el procedimiento anterior, los pasos 1 y 2 esencialmente separan el componente de tendencia-ciclo TC_t de la serie. Pero se pueden aplicar muchos métodos distintos.
- En la siguiente sección consideraremos otras opciones de suavizamiento de la serie.
- Hay otros métodos de descomposición que incorporan otros métodos más sofisticados para obtener alguno de los componentes (tendencia o estacionalidad), por ejemplo:
 - Método STL
 - Método X-12-ARIMA

- Al promedio móvil de un promedio móvil se le llama **promedio móvil doble**. El propósito de hacer promedios móviles dobles es centrar las observaciones, en el sentido de hacer los pesos simétricos.
- Un promedio móvil de orden k de un promedio móvil de orden m se denota como $k \times m - MA$.
- Los promedios móviles dobles o triples generan promedios ponderados de las observaciones con diferentes pesos. Por ejemplo, un promedio $2 \times 4 - MA$ nos da:

$$\begin{aligned}\hat{T}_t &= \frac{1}{2} \left[\frac{1}{4}(y_{t-2} + y_{t-1} + y_t + y_{t+1}) + \frac{1}{4}(y_{t-1} + y_t + y_{t+1} + y_{t+2}) \right] \\ &= \frac{1}{8}y_{t-2} + \frac{1}{4}y_{t-1} + \frac{1}{4}y_t + \frac{1}{4}y_{t+1} + \frac{1}{8}y_{t+2}\end{aligned}$$

- Estos promedios ponderados también se conocen como *filtros*, y algunos son muy utilizados, como veremos más adelante.


Método de descomposición STL I

- El método STL (*Seasonal and Trend decomposition using loess*) es un método robusto y versátil que utiliza un método conocido como *loess* para estimar relaciones no lineales.
- Sus principales ventajas incluyen:
 - Puede manejar cualquier periodicidad de estacionalidad
 - Se permite al componente estacional cambiar a lo largo del tiempo.
 - El nivel de suavizamiento de la tendencia se puede controlar.
 - Es robusto ante la presencia de valores extremos (outliers).
- El siguiente código considera que:
 - `s.window` es la ventana de loess para el ajuste estacional, en rezagos, o se especifica *periodic* para tomar la media.
 - `t.window` es la ventana de loess para la tendencia (en rezagos)

Método de descomposición STL II

```
m.stl <- stl(ts.pasajeros, t.window=4, s.window="periodic", robust = T)
plot(m.stl)
```

Método de descomposición STL III



1 **Análisis de series de tiempo**

- Introducción a las series de tiempo
- Enfoque descriptivo (Descomposición de series temporales)
- **Suavizamiento**
- Suavizamiento Avanzado

2 **Modelos ARIMA**

- Metodología de Box-Jenkins
- Análisis Box-Jenkins
- Ruido blanco
- Modelos AR, MA y ARMA

3 **Anexo**

- Los métodos de suavizamiento utilizan los datos históricos para obtener un valor “suavizado”: remueve o disminuye la variabilidad de la serie, como se vió en el método de descomposición, pasos 1 y 2.
- Estos métodos se pueden utilizar como método de descomposición y como un método para obtener *pronósticos de corto plazo*.
- Dentro de los métodos de suavizamiento hay 2 clases que se utilizan mucho en la práctica:
 - *Métodos de promedio*: se calculan promedios ponderados para las observaciones de la serie.
 - *Métodos de suavizamiento exponencial*: se asignan pesos a las observaciones de tal forma que los datos más viejos tienen menor relevancia.

Datos para los ejemplos I

- En los métodos que veremos a continuación suponemos que tenemos una serie de tiempo $\{y_t\}$.
- Para propósitos ilustrativos, consideren la siguiente serie mensual de precios de algún producto. El primer dato corresponde a enero de 1980:

```
library(forecast)
data(wineind) # datos de ventas de vino
(yt <- wineind)
```


	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
1980	15136	16733	20016	17708	18019	19227	22893	23739	21133	22591	26786	29740
1981	15028	17977	20008	21354	19498	22125	25817	28779	20960	22254	27392	29945
1982	16933	17892	20533	23569	22417	22084	26580	27454	24081	23451	28991	31386
1983	16896	20045	23471	21747	25621	23859	25500	30998	24475	23145	29701	34365
1984	17556	22077	25702	22214	26886	23191	27831	35406	23195	25110	30009	36242
1985	18450	21845	26488	22394	28057	25451	24872	33424	24052	28449	33533	37351
1986	19969	21701	26249	24493	24603	26485	30723	34569	26689	26157	32064	38870
1987	21337	19419	23166	28286	24570	24001	33151	24878	26804	28967	33311	40226
1988	20504	23060	23562	27562	23940	24584	34303	25517	23494	29095	32903	34379
1989	16991	21109	23740	25552	21752	20294	29009	25500	24166	26960	31222	38641
1990	14672	17543	25453	32683	22449	22316	27595	25451	25421	25288	32568	35110
1991	16052	22146	21198	19543	22084	23816	29961	26773	26635	26972	30207	38687
1992	16974	21697	24179	23757	25013	24019	30345	24488	25156	25650	30923	37240
1993	17466	19463	24352	26805	25236	24735	29356	31234	22724	28496	32857	37198
1994	13652	22784	23565	26323	23779	27549	29660	23356				

Datos para los ejemplos II

- Para darnos una idea de los datos:

```
plot(yt)
```

Datos para los ejemplos III



- La diferencia entre el valor de la serie suavizada y la observación, es el *error*. Es similar a los residuales.

Promedios simples I

- Los promedios simples son los más sencillos de calcular.
- Este método consiste en usar como pronóstico F_t el promedio de todas las observaciones disponibles hasta el tiempo $t - 1$,

$$F_t = \sum_{i=1}^{t-1} \frac{y_i}{t-1}$$

```
(Ft <- mean(yt))  
[1] 25392.15
```

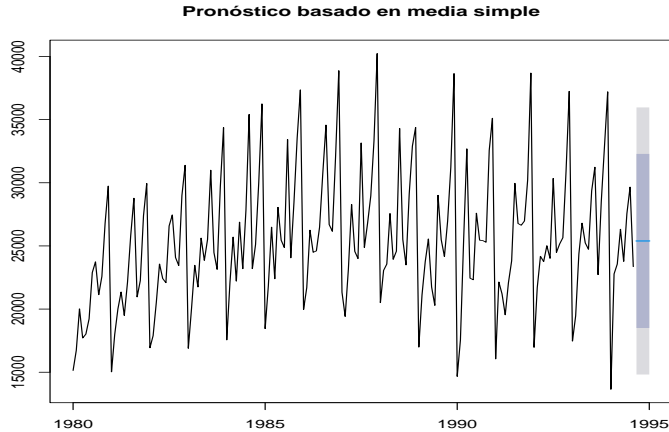
- A partir de este dato, se supone que el pronóstico h pasos adelante es constante. El paquete `forecast` hace el cálculo

```
meanf(yt,h=5) # horizonte de h=5 periodos
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Sep 1994	25392.15	18502.18	32282.11	14821.53	35962.76
Oct 1994	25392.15	18502.18	32282.11	14821.53	35962.76
Nov 1994	25392.15	18502.18	32282.11	14821.53	35962.76
Dec 1994	25392.15	18502.18	32282.11	14821.53	35962.76
Jan 1995	25392.15	18502.18	32282.11	14821.53	35962.76

```
plot(meanf(yt,h=5), main="Pronóstico basado en media simple")
```

Promedios simples II



- Usualmente, este método no genera buenos pronósticos si la serie muestra una tendencia marcada. Sólo es apropiada cuando la serie es estacionaria: tiene un comportamiento muy regular en el tiempo.
- Una limitación es que le da la misma importancia a todos los puntos, inclusive los más alejados.


- EL pronóstico ingenuo consiste simplemente en tomar como pronóstico el último dato observado. Es una alternativa al promedio simple.

```
naive(yt,h=5)
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Sep 1994	23356	14678.259	32033.74	10084.5401	36627.46
Oct 1994	23356	11083.821	35628.18	4587.3214	42124.68
Nov 1994	23356	8325.711	38386.29	369.1571	46342.84
Dec 1994	23356	6000.518	40711.48	-3186.9199	49898.92
Jan 1995	23356	3951.981	42760.02	-6319.8866	53031.89

```
plot(naive(yt,h=5), main = "Pronóstico ingenuo")
```

Pronóstico ingenuo II



Promedios móviles (MA) I

- Un *promedio móvil simple de orden k* para el tiempo t se define como el promedio de las k observaciones anteriores a t :

$$F_t^{(k)} = \frac{y_{t-1} + y_{t-2} + \cdots + y_{t-k}}{k} = \frac{1}{k} \sum_{i=1}^k y_{t-i}$$

- Un promedio móvil de orden k se denota como $MA(k)$.
- La fórmula anterior se puede expresar de forma recursiva:

$$F_{t+1}^{(k)} = F_t^{(k)} + \frac{y_{t+1} - y_{t-k}}{k},$$

de este modo, cada nuevo pronóstico es un ajuste del pronóstico precedente. Este ajuste es cada vez más pequeño conforme k es mayor.

Promedios móviles (MA) II


```
options(width = 150)
(ma5 <- ma(yt, order = 5))
```

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
1980	NA	NA	17522.4	18340.6	19572.6	20317.2	21002.2	21916.6	23428.4	24797.8	23055.6	22424.4
1981	21907.8	20821.4	18773.0	20192.4	21760.4	23514.6	23435.8	23987.0	25040.4	25866.0	23496.8	22883.2
1982	22539.0	21774.4	20268.8	21299.0	23036.6	24420.8	24523.2	24730.0	26111.4	27072.6	24961.0	24153.8
1983	24157.8	22709.0	21556.0	22948.6	24039.6	25545.0	26090.6	25595.4	26763.8	28536.8	25848.4	25368.8
1984	25880.2	24382.8	22887.0	24014.0	25164.8	27105.6	27301.8	26946.6	28310.2	29992.4	26601.2	26331.2
1985	26606.8	25083.8	23446.8	24847.0	25452.4	26839.6	27171.2	27249.6	28866.0	31361.8	28670.8	28200.6
1986	27760.6	25952.6	23403.0	24706.2	26510.6	28174.6	28613.8	28924.6	30040.4	31669.8	29023.4	27569.4
1987	26971.2	26215.6	23355.6	23888.4	26634.8	26977.2	26680.8	27560.2	29422.2	30837.2	29962.4	29213.6
1988	28132.6	26982.8	23725.6	24541.6	26790.2	27181.2	26367.6	27398.6	29062.4	29077.6	27372.4	26895.4
1989	25824.4	24354.2	21828.8	22489.4	24069.4	24421.4	24144.2	25185.8	27371.4	29297.8	27132.2	25807.6
1990	25506.2	25798.4	22560.0	24088.8	26099.2	26098.8	24646.4	25214.2	27264.6	28767.6	26887.8	26232.8
1991	25414.8	22809.8	20204.6	21757.4	23320.4	24435.4	25853.8	26831.4	28109.6	29854.8	27895.0	26907.4
1992	26348.8	25058.8	22324.0	23733.0	25462.6	25524.4	25804.2	25931.6	27312.4	28691.4	27287.0	26148.4
1993	25888.8	25065.2	22664.4	24118.2	26096.8	27473.2	26657.0	27309.0	28933.4	30501.8	26985.4	26997.4
1994	26011.2	24704.4	22020.6	24800.0	26175.2	26133.4	NA	NA				

La gráfica que obtenemos es la siguiente:

```
plot(yt)
lines(ma5,col="red")
```

Promedios móviles (MA) III



Promedios móviles (MA) IV

- Usualmente el promedio móvil sirve para suavizar una serie. Pero se puede hacer un pronóstico utilizando la serie suavizada, por ejemplo:

```
F5 <- forecast(ma(yt, order=5), h=10)
```

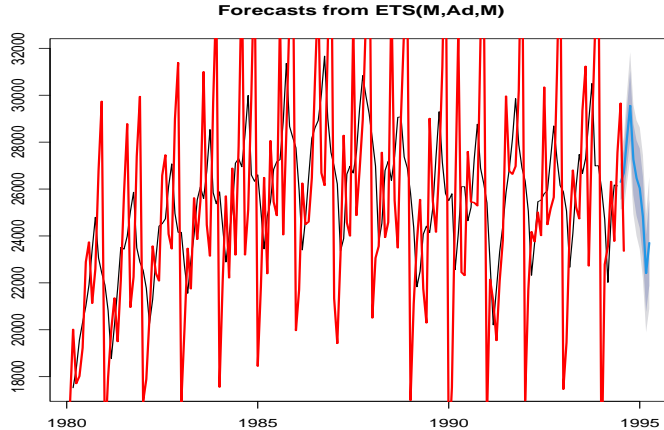
```
F5
```

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jul 1994	26296.76	25539.29	27054.22	25138.31	27455.20	
Aug 1994	26682.84	25684.16	27681.52	25155.49	28210.18	
Sep 1994	28178.43	26927.06	29429.80	26264.62	30092.24	
Oct 1994	29557.62	28066.89	31048.35	27277.74	31837.49	
Nov 1994	27263.91	25742.16	28785.66	24936.60	29591.22	
Dec 1994	26466.34	24859.23	28073.46	24008.48	28924.21	
Jan 1995	26032.26	24333.30	27731.23	23433.92	28630.60	
Feb 1995	24811.77	23087.10	26536.44	22174.11	27449.43	
Mar 1995	22411.32	20763.80	24058.85	19891.65	24931.00	
Apr 1995	23709.43	21876.44	25542.42	20906.12	26512.75	

```
plot(F5)
```

```
lines(yt, col = "red", lwd = 2)
```

Promedios móviles (MA) V



Observaciones a los promedios móviles

- Mientras más grande es el orden k de un promedio móvil, el efecto de suavizamiento es mayor.
- ¿Cómo se escoge k ? Para comparar la calidad de diferentes métodos de suavizamiento se requiere una medida de la asociación entre y_t y el pronóstico F_t .
- A continuación veremos varias medidas de calidad de un pronóstico.
- Este método es apropiado para series que tienen tendencia sin grandes variaciones.

Medidas de calidad para los pronósticos I

- Una vez que se obtienen los residuales, se pueden aplicar varias medidas para tener una forma de comparar entre métodos. Las medidas usuales son las que se describen a continuación. Se tienen $m = N - k$ residuales e_1, e_2, \dots, e_m .
 - Error medio (ME): $\bar{e} = \frac{\sum_{i=1}^m e_i}{m}$.
 - Error medio absoluto (MAE): $\frac{\sum_{i=1}^m |e_i|}{m}$.
 - Error cuadrático medio (MSE): $\frac{\sum_{i=1}^m e_i^2}{m}$.
 - Error porcentual medio (MPE): $\frac{1}{m} \sum_{i=1}^m (100 \times e_i / Y_i)$.
 - Error porcentual medio absoluto (MAPE): $\frac{1}{m} \sum_{i=1}^m 100 \times |e_i / Y_i|$.
- Podemos usar la función `accuracy` para obtener todas las medidas calculadas:

```
accuracy(F5)
```

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	-16.36168	545.6951	420.4824	-0.09829481	1.653005	0.3738074	0.04089187

Suavizamiento exponencial simple I

- Hay situaciones en donde las observaciones más recientes contienen información más actualizada sobre lo que se espera en el futuro y por lo tanto, se les tiene que dar un peso mayor que a las observaciones más antiguas.
- El método de suavización exponencial calcula el pronóstico como una combinación entre el pronóstico del periodo anterior y la última observación disponible:

$$F_t(\alpha) = \alpha y_{t-1} + (1 - \alpha)F_{t-1}$$

donde al parámetro α se le llama factor de suavizamiento, $\alpha \in (0, 1)$ es un peso que pondera la relación entre ambos términos.

Suavizamiento exponencial simple II

- Haciendo una sustitución recursiva, podemos ver que:

$$\begin{aligned}F_{t+1} &= \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \cdots \\&= \alpha \sum_{i=0}^{\infty} (1 - \alpha)^i y_{t-i}\end{aligned}$$

así que el suavizamiento exponencial obtiene su nombre de esta expresión.

- El pronóstico también se puede escribir como

$$F_{t+1} = F_t + \alpha(y_t - F_t) = F_t + e_t$$

así que un nuevo pronóstico es un ajuste del pronóstico anterior, agregando el error.


- Si $\alpha \rightarrow 0$, casi no hay ajuste y el pronóstico tiende a estar muy suavizado. Si $\alpha \rightarrow 1$, la última observación se vuelve más importante, y casi no hay suavizamiento.
- Se puede buscar un valor óptimo para α minimizando alguna de las funciones de error, como el error cuadrático medio, que definiremos a continuación.

Suavizamiento exponencial simple III

- En la práctica el suavizamiento exponencial es muy usado, ya que es un método preciso, efectivo y práctico.
- Para suavizamiento exponencial, podemos usar la función `ses` del paquete `forecast`

```
se1 <- ses(yt, alpha=0.3)
plot(yt)
lines(se1$fitted,col="red") # valores ajustados
```

Suavizamiento exponencial simple IV

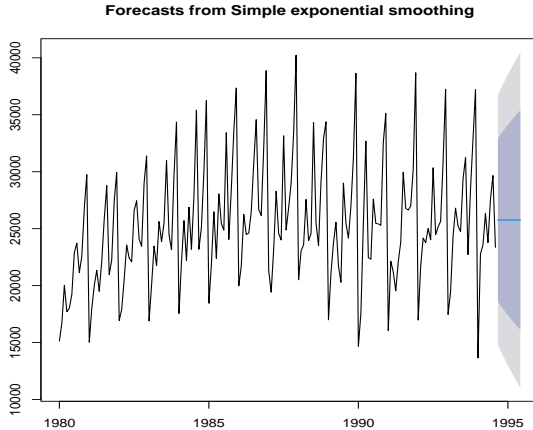


Suavizamiento exponencial simple V

- El pronóstico utilizando suavizamiento exponencial

```
plot(se1)
```

Suavizamiento exponencial simple VI



Método lineal de Holt

- El modelo de Holt (1957) es una extensión del modelo de suavizamiento exponencial para datos con tendencia.
- En este método se plantean tres ecuaciones: una ecuación para el nivel, una para la pendiente (nivel y pendiente hacen la tendencia-ciclo) y otra de pronóstico:

$$\begin{aligned}L_t &= \alpha y_t + (1 - \alpha)(L_{t-1} + b_{t-1}) \\ b_t &= \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1} \\ F_{t+m} &= L_t + b_t m\end{aligned}$$

donde L_t representa el nivel de la serie al tiempo t , y b_t es la pendiente de la tendencia. El parámetro α pondera el nivel estimado en el punto anterior y el nivel de la observación actual, mientras que β pondera a la pendiente.

- Se requiere inicializar L_t y b_t . En cada caso respectivamente, se toma $L_1 = y_1$ y $b_1 = y_2 - y_1$.

Ejemplo I

- Considerando $\alpha = 0.5$ y $\beta = 0.1$, y con los datos que se muestran a continuación, se puede construir un cuadro como el que se muestra a continuación.

t	y_t	L_t	b_t
1	200	200	-65
2	135	135	-65
3	195	132.5	-58.75
4	197.5	135.6	-52.56
5	310	196.5	-41.21

- Para cada tiempo se puede calcular una serie de pronósticos para un horizonte dado. Por ejemplo, en el primer periodo, la serie de valores pronosticados es:

$$F_1 = L_1 = 200, \quad F_2 = L_1 + b_1 = 135, \quad F_3 = 70, \quad F_4 = 5, \quad F_5 = -60$$

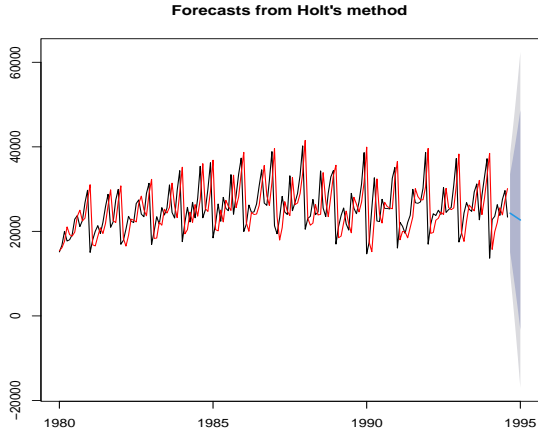
para el segundo periodo, la serie de valores es:

$$F_2 = L_2 = 135, \quad F_3 = L_2 + b_2 = 65, \quad F_4 = 5 \quad \dots$$

Con una serie larga y una buena selección de parámetros, el modelo elegido mejora la calidad de los pronósticos.

```
h1 <- holt(yt, alpha=0.8,beta=0.2, h=5)
plot(h1)
lines(h1$fitted, col = "red")
```

Ejemplo III



Selección de los parámetros

- Para escoger los valores más convenientes de α y β , se selecciona una función adecuada de los errores, como el error cuadrático medio, y se considera como función de los parámetros: $MSE(\alpha, \beta)$.
- Los mejores parámetros son los que minimizan tal función.
- Cuando $\alpha = \beta$, el método se conoce como *Suavizamiento exponencial doble de Brown*.

Método de Holt-Winters I

- Los modelos de suavizamiento exponencial y el modelo de Holt son típicamente adecuados para datos sin estacionalidad.
- El método de Holt-Winters está diseñado para datos estacionales.
- Winters (1960) extendió el método de Holt, y hay dos versiones dependiendo de cómo se modele la estacionalidad (aditiva o multiplicativa).
- En este caso se tienen 4 ecuaciones y 3 parámetros:

$$\text{Nivel } L_t = \alpha \frac{y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + b_{t-1})$$

$$\text{Tendencia } b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$$

$$\text{Estacional } S_t = \gamma \frac{y_t}{L_t} + (1 - \gamma)S_{t-s}$$

$$\text{Pronóstico } F_{t+m} = (L_t + b_t m)S_{t-s+m}$$

donde s es la longitud de la estacionalidad.

- Inicialización: Se necesitan valores iniciales para L_t , b_t y los índices estacionales S_t .
 - S_t : requiere los datos completos de una estación, y $S_i = \frac{y_i}{L_s}$.
 - L_t : Se calcula el valor para s : $L_s = \frac{1}{s}(y_1 + \dots + y_s)$.
 - b_t : Se calcula el valor para s : $b_s = \frac{1}{s}(\frac{y_{s+1}-y_1}{s} + \dots + \frac{y_{2s}-y_s}{s})$.
- Los valores de α , β y γ se eligen de tal forma que minimizen $MSE(\alpha, \beta, \gamma)$.
- En R, la función `HoltWinters` permite definir un ajuste considerando un modelo aditivo o multiplicativo, e incluye como casos particulares el modelo de Holt ($\gamma = 0$) y el modelo de suavizamiento exponencial (con $\gamma = 0$, $\beta = 0$). Aquí R encuentra los valores óptimos si no son dados.

Ejemplos de Holt-Winters

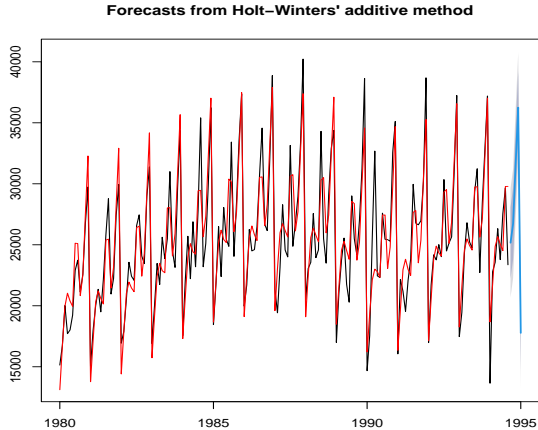
```
(m <- hw(yt,h=5)) # aditivo por default, elige valores óptimos opr default
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Sep 1994	25158.19	22234.62	28081.75	20686.98	29629.39
Oct 1994	26727.87	23799.28	29656.47	22248.97	31206.78
Nov 1994	31594.46	28658.18	34530.74	27103.81	36085.11
Dec 1994	36249.81	33302.67	39196.96	31742.54	40757.08
Jan 1995	17765.61	14803.89	20727.33	13236.05	22295.18

Ejemplos de Holt-Winters I

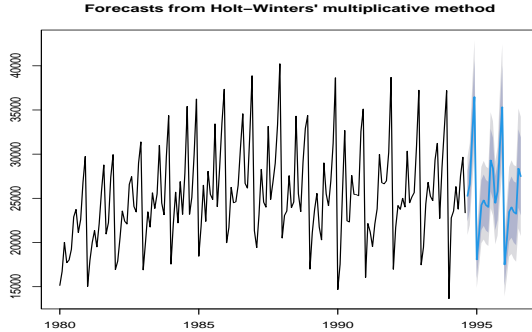
```
plot(m)  
lines(m$fitted,col="red")
```


Ejemplos de Holt-Winters II



Ejemplos de Holt-Winters III

```
# Ahora consideramos un modelo multiplicativo  
m <- hw(yt, seasonal = "mult")  
plot(m)
```



1 **Análisis de series de tiempo**

- Introducción a las series de tiempo
- Enfoque descriptivo (Descomposición de series temporales)
- Suavizamiento
- **Suavizamiento Avanzado**

2 Modelos ARIMA

- Metodología de Box-Jenkins
- Análisis Box-Jenkins
- Ruido blanco
- Modelos AR, MA y ARMA

3 Anexo

Otros comentarios sobre la estacionalidad I

- Hasta ahora hemos visto que una serie de tiempo puede descomponerse en:
 - 1 Tendencia T_t , que es el movimiento suave que indica la dirección de movimiento de la serie en el largo plazo
 - 2 Ciclo C_t , que indica el movimiento en forma de onda, superpuesto a la tendencia y cuya duración típicamente es mayor a un año.
 - 3 la Estacionalidad S_t , que es un movimiento periódico que se da en un año y (iv) el Error E_t que representa la parte irregular y aleatoria de la serie.
- El interés de descomponer una serie de tiempo desde el punto de vista económico es tratar de aislar cada componente y poder interpretar y predecir su comportamiento de manera separada. Usualmente se considera que las posibles causas que generan la estacionalidad, por ejemplo, no son de naturaleza económica.
- Granger identificó cuatro posibles causas de las fluctuaciones estacionales:
 - Calendario: algunas fiestas sociales se celebran en fechas específicas, los meses tienen diferente número de días.
 - Actividades fijadas por instituciones: pago de impuestos, periodos vacacionales, etc.
 - Clima: las estaciones del año determinan las cosechas, la cobertura de ciertos riesgos, etc.
 - Expectativas de fluctuaciones estacionales: la Navidad genera una expectativa de venta de juguetes, por ejemplo.

- Es por las razones previas que desde un punto de vista económico, es conveniente desestacionalizar las series o ajustarlas estacionalmente.

Ejemplos de promedios móviles ponderados $WMA(k)$

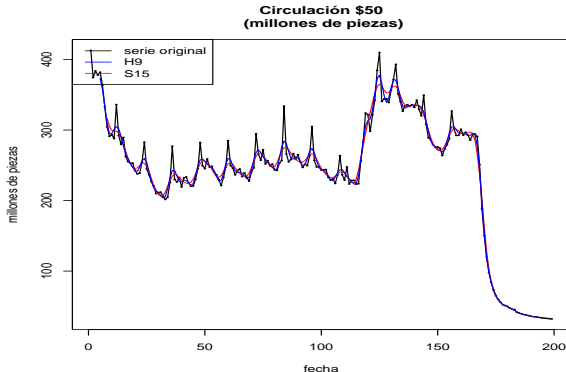
Algunos promedios móviles ponderados especiales han sido de utilidad para separar el componente de tendencia-ciclo:

- **filtro de Spencer (1904)** propuso un $5 \times 4 \times 4MA$ seguido de un promedio móvil ponderado con pesos $a_{-2} = a_2 = -\frac{3}{4}, a_0 = 1, a_{-1} = a_1 = \frac{3}{4}$. Esta combinación es equivalente al promedio $WMA(15)$ con pesos $\frac{1}{320}(-3, -6, -5, 3, 21, 46, 67, 74, 67, 46, 21, 3, -5, -6, -3)$. Este filtro se conoce como $S15$.
- $3 \times 5MA$ es equivalente a un $WMA(4)$ con pesos $(0.200, 0.200, 0.133, 0.067)$.
- **filtro de Henderson (1914)**, $H9 = (0.33, 0.267, 0.119, -0.010, -0.041)$.

La función `filter` en R permite suavizar una serie de tiempo calculando el promedio de las observaciones con los pesos que se le dan como argumento.

Ejemplo: Ajustes de Promedios ponderados especiales

```
den <- read.csv(paste0(ruta,"denom.csv"))
plot.ts(den$x50, ylab = "millones de piezas", xlab = "fecha")
points(den$x50,pch=16,cex=0.4)
S15 <- c(-3,-6,-5,3,21,46,67,74,67,46,21,3,-5,-6,-3)/320
H9 <- c(-0.04072, -0.00987, 0.11847, 0.33114, 0.26656, 0.11847, -0.00987, -0.04072)
lines(filter(den$x50,filter=S15),col="red")
lines(filter(den$x50,filter=H9),col="blue")
title("Circulación $50\n (millones de piezas)")
legend("topleft",legend=c("serie original","H9","S15"),col=c("black","blue","red"),lty=c(1,1))
```



Suavizamiento de regresión local

- Este modelo ajusta rectas a secciones de los datos. La tendencia en t está dada por $T_t = a_t + b_t t$ donde

$$(a_t, b_t) = \arg_{min} \left\{ \sum_{j=-m}^m a_j (Y_{t+j} - a - b(t+j))^2 \right\}$$

los pesos a_j determinan el peso de cada observación, y $m = \frac{k-1}{2}$


- En cada punto t se ajusta un valor. En los extremos se requiere hacer modificaciones para evitar sesgos.
- En este caso no mostraré un ejemplo porque la programación es tediosa y este es un paso intermedio para llegar a un mejor estimador, que es *loess*, como veremos adelante.

loess (*local estimate scatterplot smoothing*)

- Es una implementación del suavizamiento de regresión local que es robusto ante valores extremos (outliers), que se obtiene de realizar varias iteraciones:
 - i. Calcula una regresión local \hat{T}_t
 - ii. Estima el error de ajuste $\hat{E}_t = Y_t - \hat{T}_t$
 - iii. Ajusta los pesos a_j de tal manera que las observaciones con errores grandes E_t , reciban un peso menor y tengan menos influencia sobre el ajuste.
 - iv. Repetir el paso (i) y los que siguen hasta convergencia.

Ejemplo de ajuste loess

```
z <- loess(den$x100 ~ time(den$x100))
plot.ts(ts(den$x100, start = c(1993,01), freq=12), ylab = "millones de piezas", xlab = "fecha")
lines(ts(z$fit, start = c(1993,01), freq = 12), col = "green", lwd = 2)
lines(ts(loess(den$x100 ~ time(den$x100), span = 0.5)$fit, start = c(1993, 01), freq = 12), col = "orange", lwd = 2)
lines(ts(loess(den$x100 ~ time(den$x100), span = 0.2)$fit, start = c(1993, 01), freq = 12), col = "violet", lwd = 2)
legend("bottomright", legend = c(0.75, 0.5, 0.2), col = c("green", "orange", "violet"), lty = c(1,1,1), lwd=c(2,2,2))
```



- Como refinación a los métodos presentados previamente, y considerando que en estructuras más complejas la descomposición es más compleja, surge un procedimiento en donde se aplican de manera iterativa promedios móviles ponderados.
- El método Census II surgió en 1955 y ha tenido varias variantes experimentales, llamadas X-1 a X-13. Estos métodos siguen siendo utilizados por varias agencias experimentales en todo el mundo.
- El sitio <http://www.seasonal.website> presenta las facilidades completas para justas series de tiempo con este método.

Modelos ARIMA

- 1 **Análisis de series de tiempo**
 - Introducción a las series de tiempo
 - Enfoque descriptivo (Descomposición de series temporales)
 - Suavizamiento
 - Suavizamiento Avanzado

- 2 **Modelos ARIMA**
 - Metodología de Box-Jenkins
 - Análisis Box-Jenkins
 - Ruido blanco
 - Modelos AR, MA y ARMA

- 3 **Anexo**

- Como se ha mencionado, hay dos aspectos a estudiar en las series de tiempo: uno es el análisis, y el otro es la modelación.
- Los modelos más comunes de series de tiempo son conocidos como **modelos ARIMA**, que significa: *Autoregressive, Integrated, Moving Average*. Estos modelos describen *series estacionarias*.
- Estos modelos fueron propuestos en los 70's por George Box y Gwilym Jenkins y son esenciales para entender otros modelos mucho más complicados que se utilizan en la práctica, como los modelos ARCH y GARCH, los modelos de espacio de estados, los modelos de cadenas de Markov ocultos, los modelos dinámicos lineales, etc.
- Robert F. Engle y Clive Granger obtuvieron el premio Nobel 2004 “for methods of analyzing economic time series with time-varying volatility (ARCH)” y “for methods of analyzing economic time series with common trends (cointegration)” respectivamente. Este comentario es sólo para enfatizar la importancia de los modelos ARIMA.

- Lo dividiremos en 4 fases:
 - I. *Identificación*: preparación de los datos y selección del modelo. Utiliza los datos históricos para identificar un modelo apropiado.
 - II. *Estimación*: estima los parámetros de modelos potenciales y selecciona el mejor modelo.
 - III. *Diagnósticos*: se utilizan varios diagnósticos para evaluar si el modelo es adecuado.
 - IV. *Aplicación*: se usa el modelo para hacer pronósticos y otros estudios.
- Las primeras dos fases pueden repetirse si los diagnósticos indican que los modelos no son adecuados.
- En la sesión de hoy, seguiremos el desarrollo de estos pasos a través de ejemplos, y se irán introduciendo los conceptos necesarios conforme se utilicen.

- 1 **Análisis de series de tiempo**
 - Introducción a las series de tiempo
 - Enfoque descriptivo (Descomposición de series temporales)
 - Suavizamiento
 - Suavizamiento Avanzado

- 2 **Modelos ARIMA**
 - Metodología de Box-Jenkins
 - **Análisis Box-Jenkins**
 - Ruido blanco
 - Modelos AR, MA y ARMA

- 3 **Anexo**

Lista de herramientas

Aquí agrego un resumen de las herramientas que son necesarias para hacer un análisis de series de tiempo tipo Box-Jenkins. Algunas son necesarias para construir el modelo y otras son necesarias para diagnosticar el modelo.

- 1 Gráficas de las series de tiempo.
- 2 Concepto de estacionariedad, operador diferencia y prueba de estacionariedad de Dickey-Fuller.
- 3 Conceptos de autocorrelación y autocorrelación parcial y sus respectivas funciones y gráficas (acf, pacf)
- 4 Concepto y gráficas de ruido blanco.
- 5 Pruebas estadísticas para coeficientes de autocorrelación de Bartlett, y de Ljung-Box.
- 6 Definiciones de procesos: autoregresivo (AR), de promedios móviles (MA).


En lo que sigue, se dará un repaso muy general de estos conceptos, y veremos varios ejemplos para ir aplicando los conceptos.

Ejemplo: Kleenex I

Para conocer el margen de mercado que tiene Kimberly-Clark con la marca kleenex, se le han pedido su producción semanal, que reporta para las 120 semanas anteriores a ésta y en unidades de 10,000 paquetes. Se requiere un modelo para analizar su comportamiento y hacer un pronóstico para saber si no está inundando el mercado.

```
kleenex <- read.table(file = paste0(ruta,"kleenex.txt")) # lee los datos
kleenex <- ts(kleenex, start = 1, freq = 52) # convierte a una serie con frecuencia semanal.
plot(kleenex, main = "Valores originales de la serie", xlab = "Tiempo", ylab = "paquetes de kleenex")
```

Ejemplo: Kleenex II



La primera pregunta que nos debemos hacer es si esta serie tiene un comportamiento *estacionario*

Series estacionarias I

- Intuitivamente, una serie es estacionaria si ciertas propiedades estadísticas, por ejemplo la media y la varianza, son esencialmente constantes en el tiempo.
- Si una gráfica de la serie de n puntos no muestra que los valores y_1, y_2, \dots, y_n sean no estacionarios, a veces se puede transformar la serie no estacionaria en estacionaria *diferenciando la serie*:

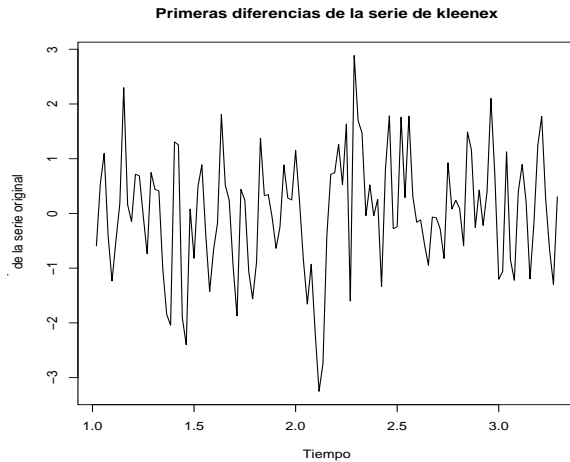
$$z_t = y_t - y_{t-1} \quad \text{para } t = 2, \dots, n$$

```
dkleenex <- diff(kleenex, differences = 1)
head(dkleenex)

Time Series:
Start = c(1, 2)
End = c(1, 7)
Frequency = 52
      V1
[1,] -0.5936
[2,]  0.5319
[3,]  1.0991
[4,] -0.4054
[5,] -1.2345
[6,] -0.5016

plot(dkleenex, main = "Primeras diferencias de la serie de kleenex", xlab = "Tiempo",
      ylab = "primeras diferencias\n de la serie original")
```

Series estacionales II



- Ahora la serie parece fluctuar alrededor de una media constante, por lo que la primera diferencia parece ser estacionaria.
- En ocasiones no es suficiente tomar sólo una diferencia. Si la primera diferencia no resulta estacionaria, entonces debemos tomar una segunda diferencia. Esto es tan común que conviene introducir un poco de notación.
- También hay que identificar observaciones inusuales (*outliers*) y Decidir si se requiere de una transformación de la serie de tiempo para estabilizar la varianza. Si se requiere, transforma la serie para hacer que la varianza parezca más constante (aplicando las transformaciones usuales, como obtener logaritmos, raíces cuadradas, Box-Cox, etc.)

Operadores rezago y diferencia I

- Definan al operador rezago como la función L (de *lag*) tal que $La_t = a_{t-1}$
- En general, se puede tener un rezago de orden j : $L^j a_t = a_{t-j}$. Por convención, se toma $L^0 = 1$
- De la misma forma, podemos definir el operador diferencia como $\Delta a_t = a_t - a_{t-1}$
- De hecho, notemos que ambos operadores, rezago y diferencia, están relacionados a través de la fórmula:

$$\Delta = 1 - L$$

ya que $(1 - L)a_t = a_t - La_t = a_t - a_{t-1} = \Delta a_t$.

- Podemos tomar también la segunda diferencia, la tercera diferencia, etc. de la siguiente manera:

1a. dif $\Delta y_t = y_t - y_{t-1}$

2a. dif $\Delta^2 y_t = \Delta(\Delta y_t) = \Delta y_t - \Delta y_{t-1} = y_t - 2y_{t-1} + y_{t-2}$.

3a. dif $\Delta^3 y_t = \Delta(\Delta^2 y_t) = y_t - 2y_{t-1} + y_{t-2} - (y_{t-1} - 2y_{t-2} + y_{t-3}) = y_t - 3y_{t-1} + 3y_{t-2} - y_{t-3}$.

- En la práctica, si la serie original $\{y_t\}$ *no es estacionaria y no tiene un patrón estacional* entonces tomando la primera diferencia Δy_t o la segunda diferencia $\Delta^2 y_t$ usualmente hará la serie estacionaria.
- Sin embargo, si la serie original *no es estacionaria y tiene un patrón estacional*, entonces requerirá transformaciones más complejas, utilizando el operador de diferencia estacional.

Ejemplo I

```
x <- ts(1:5)
cbind(x, lag(x, 1), lag(x, -1))
```

Time Series:

Start = 0

End = 6

Frequency = 1

	x	lag(x, 1)	lag(x, -1)
0	NA	1	NA
1	1	2	NA
2	2	3	1
3	3	4	2
4	4	5	3
5	5	NA	4
6	NA	NA	5

Noten que el valor por omisión de $\text{lag}(x)$ es $\text{lag}(x, 1)$. Así que en R si tiene una serie x_t , entonces la serie $y_t = \text{lag}(x_t) = \text{lag}(x_t, 1) = x_{t+1}$, que es un valor adelantado y no x_{t-1} , así que para obtener Lx_t debemos usar $\text{lag}(x, -1)$.

Por otra parte, para la diferencias:

Ejemplo II

```
x <- ts(seq(2,10,by=2))
x

Time Series:
Start = 1
End = 5
Frequency = 1
[1] 2 4 6 8 10

cbind(x,diff(x,1), diff(x,2), x-lag(x,-2))

Time Series:
Start = 1
End = 5
Frequency = 1
  x diff(x, 1) diff(x, 2) x - lag(x, -2)
1 2          NA        NA             NA
2 4          2         NA             NA
3 6          2          4             4
4 8          2          4             4
5 10         2          4             4
```

El operador diferencia sí nos da los valores esperados $1 - L, (1 - L)^2$.

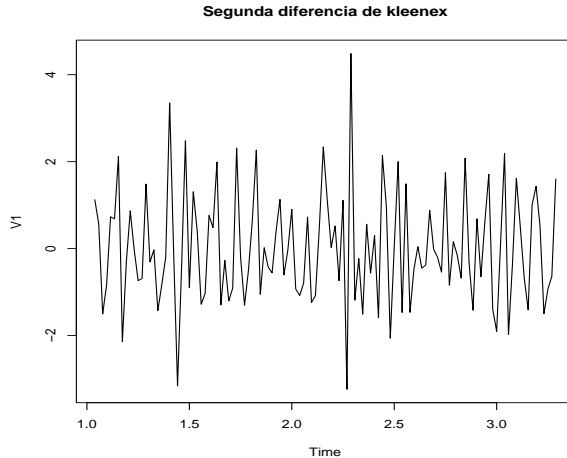
Ejemplo de segunda diferencia I

```
d2kleenex <- diff(kleenex, difference = 2)
head(d2kleenex)

Time Series:
Start = c(1, 3)
End = c(1, 8)
Frequency = 52
      V1
[1,]  1.1255
[2,]  0.5672
[3,] -1.5045
[4,] -0.8291
[5,]  0.7329
[6,]  0.6822

plot(d2kleenex, main = "Segunda diferencia de kleenex")
```

Ejemplo de segunda diferencia II



Identificando estacionariedad I

- Necesitamos un mecanismo más sólido para verificar si una serie es estacionaria. Lo haremos a través de las funciones `acf` y `pacf`.
- También se pueden considerar las pruebas más formales de Dickey-Fuller o de Phillips-Perron, que para definir las se requiere un poco más de infraestructura. No las consideraremos aquí, pero en R, son las funciones `adf.test` y `pp.test` en el paquete `tseries`.
- La *función de autocorrelación* (`acf`). Un coeficiente de autocorrelación r_k describe la relación entre valores de la serie de tiempo que están separados por k periodos.

función de autocorrelación

- El coeficiente de autocorrelación se define como:

$$r_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}$$

donde $\hat{\gamma}_k$ es la covarianza estimada entre y_t y y_{t-k} , y $\hat{\gamma}_0$ es la varianza estimada de la serie.

- r_1 indica cómo se relacionan valores sucesivos de y_t entre sí; r_2 indica cómo se relacionan valores y_t que están separados por dos periodos, etc.
- La gráfica de r_k vs. k se conoce como *correlograma*, y es una gráfica de la función de autocorrelación.

Identificando estacionariedad III

- Otra herramienta importante es la *función de autocorrelación parcial*.

función de autocorrelación parcial

- Las *autocorrelaciones parciales* se usan para medir el grado de asociación entre y_t y y_{t-k} , cuando se ha eliminado el efecto de los rezagos intermedios $1, 2, 3, \dots, k-1$.
- El coeficiente de autocorrelación parcial de orden k se denota por α_k y se calcula haciendo la regresión de y_t contra los rezagos y_{t-1}, \dots, y_{t-k} :

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \dots + \alpha_k y_{t-k}$$


- La función de autocorrelación parcial es la grafica de α_k vs. k .
- Para la serie de Kimberly, por ejemplo, podemos ver los dos casos, con la serie original y la serie diferenciada.

Identificando estacionariedad IV


```
layout(matrix(c(1,1,2,2,3,4,5,6),nrow=2,byrow=T))  
plot(kleenex, main = "Serie kleenex original")  
plot(dkleenex, main = "Serie kleenex diferenciada")  
acf(kleenex)  
pacf(kleenex)  
acf(dkleenex)  
pacf(dkleenex)
```

Identificando estacionariedad V


Serie kleenex original




Serie kleenex diferenciada




V1




Series kleenex



V1



Series dkleenex



Interpretación del correlograma I

- El correlograma sirve para explorar una serie de tiempo: verificar si la serie es estacionaria, si tiene estacionalidades, ciclos, tendencias, etc.
- Es importante validar si las autocorrelaciones son *estadísticamente significativas*, ya que cualquier $\hat{\rho}_k$ de la muestra puede diferir de cero sólo por variación en la muestra.
- Podemos darnos una idea de la importancia de la estadística muestral comparándola contra su error estándar. Un error estándar aproximado para $\hat{\rho}_k$ se obtiene de la siguiente fórmula:

$$se(\hat{\rho}(k)) = \sqrt{\frac{1 + 2 \sum_{j=1}^{k-1} \hat{\rho}_j^2}{n}}$$

Esta fórmula se conoce como la *fórmula de Bartlett*.

- En las gráficas de los correlogramas, se incluyen **líneas azules punteadas** que identifican un intervalo de 95 % para las autocorrelaciones. Si la serie de tiempo tiene *observaciones normales*, entonces también las autocorrelaciones son normales. En este caso, para probar que $\rho_k = 0$ se usa la estadística $\sqrt{T}\hat{\rho}_k$, donde T es la longitud de la serie. Se puede ver que $\sqrt{T}\hat{\rho}_k \sim \mathcal{N}(0, 1)$. Los intervalos que se muestran en el correlograma se calculan con esta estadística.
- No siempre hay que confiar en estas líneas porque son aproximadas. Se sugiere hacer una prueba formal. Las opciones son las pruebas de Box-Pierce o Ljung-Box.
- Estas estadísticas prueban la hipótesis de que las observaciones son independientes hasta el rezago h :

$$H_0 : \rho_1 = \cdots = \rho_h = 0$$

Pruebas para autocorrelaciones II

```
Box.test(dkleenex, lag = 1, type = "Box") # h= 1 en este ejemplo
```

Box-Pierce test

```
data: dkleenex  
X-squared = 11.189, df = 1, p-value = 0.000823
```

```
Box.test(dkleenex, lag = 1, type = "Ljung")
```

Box-Ljung test

```
data: dkleenex  
X-squared = 11.473, df = 1, p-value = 0.0007061
```

- La prueba de Ljung-Box es simplemente una corrección a la prueba de Box-Pierce que es más robusta bajo series de tiempo cortas. Ambas se distribuyen como χ^2 .
- La fórmula de Bartlett es la correcta.
- Usualmente se aplica esta prueba a los residuales de un modelo ajustado.

Interpretación del correlograma III

- Si la acf de una serie de tiempo decae relativamente rápido, sin importar el patrón que siga, entonces la serie de tiempo se considera estacionaria
- Si la acf no decae lentamente, entonces debe considerarse como no estacionaria.

En nuestro ejemplo, de acuerdo al criterio establecido, podemos ver que la serie original $y_t = \text{kleenex}$ no es estacionaria, pero la serie diferenciada $\Delta y_t = \text{dkleenex}$ si puede considerarse estacionaria.

- 1 **Análisis de series de tiempo**
 - Introducción a las series de tiempo
 - Enfoque descriptivo (Descomposición de series temporales)
 - Suavizamiento
 - Suavizamiento Avanzado

- 2 **Modelos ARIMA**
 - Metodología de Box-Jenkins
 - Análisis Box-Jenkins
 - **Ruido blanco**
 - Modelos AR, MA y ARMA

- 3 **Anexo**

Ejemplo: modelo de ruido blanco I

- Un modelo en el que cada observación se compone de dos partes, un nivel constante c y un componente de error ϵ_t que es independiente de cualquier periodo,




$$y_t = c + \epsilon_t$$

se le llama *ruido blanco*.

- Este modelo puede ser *simulado* usando un generador de números aleatorios normales, como la función `rnorm` en R.

```
x <- rnorm(1000,mean=5, sd=10)
layout(matrix(c(1,1,2,3),nrow=2,byrow=T))
plot.ts(x)
acf(x)
pacf(x)
```

Ejemplo: modelo de ruido blanco II



Ejemplo: modelo de ruido blanco III

- Usualmente después de ajustar un modelo, los residuales deberían comportarse similar a ruido blanco para considerar que el modelo ha sido adecuadamente ajustado.

- 1 **Análisis de series de tiempo**
 - Introducción a las series de tiempo
 - Enfoque descriptivo (Descomposición de series temporales)
 - Suavizamiento
 - Suavizamiento Avanzado

- 2 **Modelos ARIMA**
 - Metodología de Box-Jenkins
 - Análisis Box-Jenkins
 - Ruido blanco
 - Modelos AR, MA y ARMA

- 3 **Anexo**

Modelos AR

Un modelo autorregresivo de orden p , que se denota por $AR(p)$ es un modelo de la forma:

$$y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

donde $\epsilon_t \sim \mathcal{N}(0, \sigma_\epsilon^2)$, y los errores son independientes.

- En este modelo los predictores de la observación y_t son sus propios rezagos en el tiempo.
- Los modelos AR pueden ser estacionarios o no estacionarios, dependiendo de las restricciones que se impongan sobre los pesos del modelo.

Modelos MA

Un modelo de promedios móviles de orden q es un modelo de la forma:

$$y_t = \theta_0 + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q} + \epsilon_t$$

donde $\{\epsilon_t\}$ es una serie de ruido blanco.

- A este proceso se le llama promedio móvil porque es una especie de promedio móvil en la serie $\{\epsilon_t\}$, con pesos dados por los coeficientes $\theta_1, \theta_2, \dots, \theta_q$.

- Los modelos AR y MA pueden simplificarse usando los operadores rezago y diferencia, ya que podemos escribirlos como *polinomios* en L .
- Un polinomio en L de orden k es de la forma

$$\Phi_k(L) = \phi_0 L^0 + \phi_1 L^1 + \cdots \phi_k L^k,$$

donde $L^0 = 1$.

- Un $MA(q)$, se puede escribir como

$$y_t = \mu + \Theta_p(L)\epsilon_t$$

donde $\Theta_p(L) = \theta_0 L^0 + \theta_1 L^1 + \theta_2 L^2 + \dots + \theta_q L^q$ y $\theta_0 = 1$.

- Un $AR(p)$ se puede escribir como

$$\Phi_p(L)y_t = \alpha_0 + \epsilon_t$$

donde $\Phi_p(L) = 1 - \phi_1 L^1 - \phi_2 L^2 - \dots - \phi_p L^p$.

Modelos ARMA y ARIMA

- Los modelos ARMA combinan modelos autorregresivos con modelos de promedios móviles para llegar a modelos más generales.
- Un modelo ARMA(p, q) se escribe, usando notación de polinomios, como

$$\Phi_p(L)y_t = \mu + \Psi_q(L)\epsilon_t$$

- Los modelos ARMA sólo se pueden aplicar a series estacionarias. Para extender los modelos a series no estacionarias, se requiere diferenciar la serie. Esto da origen a los modelos ARIMA.
- Un modelo ARIMA(p, d, q) es un modelo ARMA(p, q) en donde la serie original y_t se reemplaza por la serie diferenciada $z_t = \Delta^d y_t$.
- En la práctica, d usualmente toma valores en $\{0, 1, 2\}$ y p y q toman valores no mayores a 4.
- Los modelos AR y MA son casos particulares de modelos ARIMA, ya que por ejemplo, un AR(p) es lo mismo que un ARIMA($p, 0, 0$), o un MA(q) es un ARIMA($0, 0, q$).

- Dada la falta de tiempo para ver en detalle las características de las funciones acf y pacf para identificar modelos, consideraremos un enfoque de *fuerza bruta* para ajustar los modelos y utilizar el criterio de Akaike para seleccionar el modelo.
- Podemos considerar ajustar todos los modelos para las combinaciones de valores p, d, q en los conjuntos $p \in \{0, 1, 2, 3, 4\}$, $d \in \{0, 1, 2\}$, y $q \in \{0, 1, 2, 3, 4\}$.
- Sin embargo, este método no funcionará para series con un fuerte componente estacional. En caso de contar con componente estacional se recomienda primero eliminar la estacionalidad con los métodos vistos previamente.
- También se pueden extender los modelos a modelos SARIMA(p, d, q)(P, D, Q), que contemplan un componente estacional, pero esos modelos son más complicados y no se verán aquí.

Ejemplo: ajuste por fuerza bruta para los datos de kleenex I

```
AIC <- array(NA, dim=c(4,2,4), dimnames = list(paste("p=",0:3), paste("d=",0:1), paste("q=",0:3)))  
for(p in 1:4) for(q in 1:4) for(d in 1:2) AIC[p,d,q] <- arima(kleenex, order = c(p-1,d-1,q-1))$aic  
AIC[,1,]
```

	q= 0	q= 1	q= 2	q= 3
p= 0	698.9005	568.3708	475.5712	437.5709
p= 1	369.6550	356.3556	358.1165	358.6551
p= 2	358.3822	358.2153	357.4390	359.2192
p= 3	357.5850	359.5559	359.2680	360.9870

```
AIC[,2,]
```

	q= 0	q= 1	q= 2	q= 3
p= 0	362.2711	349.9821	351.9519	351.8757
p= 1	352.5789	351.9658	351.3134	352.6993
p= 2	350.7612	352.7601	353.5758	353.2524
p= 3	352.7582	352.4818	349.9126	350.9945

Ejemplo: ajuste por fuerza bruta para los datos de kleenex II

El modelo que mejor ajusta estos datos está dado por el caso con el *menor* AIC, que corresponde a los valores $p = 3$, $d = 1$ y $q = 2$, sugiriendo un ajuste de la forma $\text{ARIMA}(3, 1, 2)$. No es muy distinto al valor que se tiene para el modelo con $p = 0$, $d = 1$, $q = 1$ que también puede ser un buen candidato. Entonces los modelos que se pueden proponer para valorar en los diagnósticos son los modelos $\text{ARIMA}(3, 1, 2)$ y $\text{ARIMA}(0, 1, 1)$. Usualmente, si se tienen dos o más modelos que no difieren mucho en la calidad del ajuste, siempre se escoge el más sencillo. Este es el *principio de parsimonia*.

Ejemplo: ajuste por fuerza bruta para los datos de kleenex III

```
mod1 <- arima(kleenex, order = c(3,1,2)); mod1
```

Call:

```
arima(x = kleenex, order = c(3, 1, 2))
```

Coefficients:

	ar1	ar2	ar3	ma1	ma2
	1.5308	-1.3686	0.3847	-1.2517	0.9587
s.e.	0.0876	0.1047	0.0894	0.0463	0.0711

sigma² estimated as 0.9869: log likelihood = -168.96, aic = 349.91

```
mod2 <- arima(kleenex, order = c(0,1,1)); mod2
```

Call:

```
arima(x = kleenex, order = c(0, 1, 1))
```


Coefficients:

	ma1
	0.3518
s.e.	0.0800


sigma² estimated as 1.071: log likelihood = -172.99, aic = 349.98

Diagnósticos en series de tiempo

```
tsdiag(mod1)
```



```
tsdiag(mod2)
```



Pronósticos con el modelo parsimonioso I


```
pron2 <- predict(mod2,12) # Haz una predicción de 12 periodos.
pron2

$pred
Time Series:
Start = c(3, 17)
End = c(3, 28)
Frequency = 52
[1] 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725 15.88725

$se
Time Series:
Start = c(3, 17)
End = c(3, 28)
Frequency = 52
[1] 1.034805 1.739997 2.232568 2.634602 2.982935 3.294643 3.579307 3.842943 4.089618 4.322239 4.542964 4.753450

ts.plot(kleenex, pron2$pred, pron2$pred +2*pron2$se,
pron2$pred -2*pron2$se)
```

Pronósticos con el modelo parsimonioso II



Pronósticos con el modelo complicado I


```
pron1 <- predict(mod1,12) # Haz una predicción de 12 periodos.
pron1

$pred
Time Series:
Start = c(3, 17)
End = c(3, 28)
Frequency = 52
[1] 16.05671 16.40928 16.50297 16.32213 16.05270 15.92379 16.02564 16.25434 16.41544 16.38824 16.21409 16.04669

$se
Time Series:
Start = c(3, 17)
End = c(3, 28)
Frequency = 52
[1] 0.9936002 1.6133586 2.0646103 2.4489185 2.8430614 3.2654087 3.6773496 4.0299156 4.3102502 4.5436417 4.7676635 5.0083769

ts.plot(kleenex, pron1$pred, pron1$pred +2*pron1$se,
pron1$pred -2*pron1$se)
```

Pronósticos con el modelo complicado II



Anexo

Prueba de Dickey-Fuller

- Es importante probar formalmente que una serie es estacionaria, particularmente en econometría. Las pruebas de estacionariedad se conocen como *prueba de raíz unitaria*. La prueba de Dickey-Fuller es una prueba de este tipo.
- La prueba consiste en estimar la regresión:

$$\nabla y_t = \phi y_{t-1} + \beta_1 \nabla y_{t-1} + \beta_2 \nabla y_{t-2} + \cdots + \beta_p \nabla y_{t-p} + u_t$$

donde u_t es un componente de error que se supone tiene media 0.

- Si la serie no es estacionaria, entonces se espera que $\hat{\phi} \approx 0$. Si la serie es estacionaria, entonces $\hat{\phi} < 0$.
- Como los errores de este modelo están correlacionados, los supuestos típicos de regresión lineal no se cumplen, por lo que hay que probar la hipótesis $H_0 : \phi = 0$ vs. $H_a : \phi < 0$ utilizando una prueba diferente a la prueba de t que se usa en regresión.

Prueba de Dickey-Fuller I

- La prueba se puede obtener con la función `df.test` en el paquete `tseries` de R.

```
library(tseries)
adf.test(AirPassengers, k = 0)
```

Augmented Dickey-Fuller Test

```
data: AirPassengers
Dickey-Fuller = -4.6392, Lag order = 0, p-value = 0.01
alternative hypothesis: stationary
```

```
adf.test(diff(AirPassengers,1), k = 0)
```

Augmented Dickey-Fuller Test

```
data: diff(AirPassengers, 1)
Dickey-Fuller = -8.5472, Lag order = 0, p-value = 0.01
alternative hypothesis: stationary
```

```
adf.test(diff(AirPassengers,2), k = 0)
```

Augmented Dickey-Fuller Test

```
data: diff(AirPassengers, 2)
Dickey-Fuller = -6.0136, Lag order = 0, p-value = 0.01
alternative hypothesis: stationary
```

- En la salida previa, k es el número p de componentes incluidos en la ecuación de regresión. La hipótesis alternativa dice *stationary*, ya que es el caso en el que $\phi < 0$. El p -value determina si la serie es o no estacionaria.

Identificación de modelos más generales.

- Se presenta un resumen de las características generales de los modelos $AR(p)$ y $MA(q)$ que se compararán con las acf y pacf muestrales de una serie en particular para poder *identificar* y asociar su comportamiento a algún modelo en particular.

- El modelo es $y_t = \phi_0 + \phi_1 y_{t-1} + \epsilon_t$.
- En lo que sigue, supondremos que la media de y_t es $E(y_t) = \mu$.
- Para que el proceso sea estacionario, se requiere que $|\phi_1| < 1$.
- La media, autocovarianza y autocorrelación son, respectivamente:
 - $\mu = E(y_t) = \frac{\phi_0}{1-\phi_1}$.
 - $\gamma_k = \phi_1^k \frac{\sigma_\epsilon^2}{1-\phi_1^2}$ para $k = 0, 1, 2, \dots$
 - $\rho_k = \phi_1^k$ para $k = 0, 1, 2, \dots$
- la función de autocorrelación es de la forma:

$$\rho_k = \phi_1^k, \quad k = 0, 1, 2, \dots$$

- ρ_k decae exponencialmente cuando $\phi_1 > 0$ y decae exponencialmente pero oscilando en signo cuando $\phi_1 < 0$.



- la función de autocorrelación parcial es de la forma:

$$\alpha_k = \begin{cases} \phi_1, & k = 1 \\ 0, & k > 1 \end{cases}$$

ya que en la regresión, y_t sólo depende de y_{t-1} si el proceso es estacionario.

```
par(mfrow=c(1,2))  
plot(ARMAacf(ar = 0.35, ma = 0, lag.max = 10, pacf = F))  
plot(ARMAacf(ar = 0.35, ma = 0, lag.max = 10, pacf = T))
```

$AR(1)$ III



- El modelo es $y_t = \phi_0 + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \epsilon_t$.
- Para que el proceso sea estacionario, se requiere que se cumplan estas ecuaciones simultáneamente:
 $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$ y $|\phi_2| < 1$.
- La media del proceso es $\mu = E(y_t) = \frac{\phi_0}{1 - \phi_1 - \phi_2}$.
- El cálculo de la autocovarianza teórica es complicado. Las fórmulas son recursivas (se conocen como ecuaciones de Yule-Walker):

$$\gamma_k = \begin{cases} \phi_1 \gamma_1 + \phi_2 \gamma_2 + \sigma_\epsilon^2 & \text{si } k = 0 \\ \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} & \text{si } k > 0 \end{cases}$$

- Las autocorrelaciones se obtienen usando la ecuación $\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$, para $k \geq 3$.



- Los valores de ρ_1 y ρ_2 se obtienen de resolver el sistema de ecuaciones (una vez que se conocen los valores de ϕ_1 y ϕ_2):

$$\rho_1 = \phi_1 + \phi_2 \rho_1$$

$$\rho_2 = \phi_1 \rho_1 + \phi_2$$

- Si $\phi_1^2 + 4\phi_2 \geq 0$, la acf es una mezcla de exponenciales decrecientes, y si $\phi_1^2 + 4\phi_2 < 0$, la autocorrelación es una onda sinusoidal decreciente.
- la pacf tiene picos en los rezagos 1 y 2, luego son ceros.



```
par(mfrow=c(1,2))
plot(ARMAacf(ar = c(0.35,0.5), ma = 0, lag.max = 10, pacf = F))
plot(ARMAacf(ar = c(0.35,0.5), ma = 0, lag.max = 10, pacf = T))
```



- El modelo es $y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1}$.
- El proceso es estacionario para cualquier valor de θ_1 .
- La media, autocovarianza y autocorrelación son, respectivamente:
 - $E(y_t) = \mu$.
 - $\gamma_0 = \sigma_\epsilon^2(1 + \theta_1^2)$ y
 - $\rho_k = \begin{cases} \frac{\theta_1}{1+\theta_1^2} & \text{si } k = 1 \\ 0 & \text{si } k > 1 \end{cases}$
- La acf tiene un pico en $k = 1$ y después es 0, positivo si $\theta_1 > 0$, negativo si $\theta_1 < 0$
- La pacf tiene Decae exponencialmente: del lado negativo si $\theta_1 < 0$ y alternando en signo empezando en el lado positivo si $\theta_1 > 0$.

MA(1) II



```
par(mfrow=c(1,2))  
plot(ARMAacf(ar = 0, ma = 0.42, lag.max = 10, pacf = F))  
plot(ARMAacf(ar = 0, ma = 0.42, lag.max = 10, pacf = T))
```



- El modelo es $y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$.
- El proceso es estacionario para cualquier valor de θ_1 y θ_2 .
- La media, autocovarianza y autocorrelación son, respectivamente:
 - $E(y_t) = \mu$.
 - $\gamma_0 = \sigma_\epsilon^2(1 + \theta_1^2 + \theta_2^2)$ y
 - $\rho_k = \begin{cases} \frac{\theta_1(1+\theta_2)}{1+\theta_1^2+\theta_2^2} & \text{si } k = 1 \\ \frac{\theta_2}{1+\theta_1^2+\theta_2^2} & \text{si } k = 2 \\ 0 & \text{si } k > 2 \end{cases}$
- La acf tiene un picos en los rezagos 1 y 2 y después es 0.
- Decae exponencialmente en forma de función sinoidal decreciente. El patrón exacto depende de los signos y tamaños de θ_1 y θ_2 .

MA(2) II

```
par(mfrow=c(1,2))  
plot(ARMAacf(ar = 0, ma = c(0.42,-0.3), lag.max = 10, pacf = F))  
plot(ARMAacf(ar = 0, ma = c(0.42,-0.3), lag.max = 10, pacf = T))
```



Patrones generales de acf y pacf

- La siguiente tabla resume los casos más importantes a considerar para los patrones esperados en la acf y pacf para los modelos simples AR y MA:

Proceso	acf	pacf
AR(1)	Decae exponencialmente: en el lado positivo si $\phi_1 > 0$ y alternando signo comenzando en el lado negativo si $\phi_1 < 0$	Un pico en el rezago 1, y luego 0. Pico positivo si $\phi_1 > 0$ y negativo si $\phi_1 < 0$
AR(p)	Decae exponencialmente o como en forma sinusoidal. El patrón exacto depende de los signos y magnitudes de ϕ_1, \dots, ϕ_p .	Picos de 1 a p , luego 0.
MA(1)	Pico en 1 y luego se va a 0. Pico positivo si $\theta_1 < 0$ y negativo si $\theta_1 > 0$	Decae exponencialmente: en el lado negativo si $\theta_1 > 0$ y alternando en signo comenzando en positivo si $\theta_1 < 0$.
MA(q)	Picos en los rezagos de 1 a q y luego 0.	Decae exponencialmente o como una función sinusoidal. El patrón exacto depende de los signos y tamaños de $\theta_1, \dots, \theta_q$.